

## Работа 3. ГРАДИЕНТНЫЕ МЕТОДЫ МИНИМИЗАЦИИ

### 1. Что такое градиентные методы?

Градиентные методы, как и все «поисковые» методы носят итерационный характер, т.е. включают в свой состав процедуры получения последовательности векторов (или точек) в  $N$ -мерном пространстве  $x^{(k)}$ ,  $k=0,1,2,3,\dots,K$  таких, что целевая функция  $f(x)$  на каждом шаге уменьшается:

$$f(x^{(0)}) > f(x^{(1)}) > \dots > f(x^{(k)}) > f(x^{(k+1)}) > \dots$$

Более конкретно: **градиентными** называются такие методы минимизации многомерной функции  $f(x)$ , которые вычисляют очередную точку поиска  $x^{(k+1)}$  по итерационной формуле:

$$x^{(k+1)} = x^{(k)} + t_k \cdot [s(x^{(k)})], \quad (3.1)$$

где  $x^{(k)}$  – текущая  $k$ -я точка ( $k=0,1,2,\dots,K$ ) поиска минимума  $x^*$  (напомним, что начальная точка поиска  $x^{(0)}$  задается пользователем);

$t_k$  – скаляр, определяющий длину  $k$ -го шага;

$s(x^{(k)})$  – **направление**  $k$ -го шага, которое определяется **градиентом**  $\nabla f(x)$ , либо **матрицей Гессе**  $\nabla^2 f(x)$  исходной функции  $f(x)$ .

Именно то, что в формуле (3.1) используется **направление** поиска  $s(x^{(k)})$ , зависящее от градиента, дало название большой группе методов под общим названием **градиентные методы**.

Градиентные методы разделяются на методы **первого и второго порядка**. Способ, которым вычисляется  $s(x^{(k)})$  и  $t_k$  в (3.1) определяет название метода. Напомним, что вычисление  $t_k$  осуществляется путем решения задачи одномерной минимизации  $f(x)$  в направлении  $s(x^{(k)})$  каким-либо одним из одномерных методов.

В этой работе вы подробно рассмотрите и самостоятельно запрограммируете следующие градиентные методы минимизации:

- метод **оптимального градиентного поиска (метод Коши)**;
- метод **Ньютона**;
- метод **Марквардта**.

Кроме этого, вы также сравните вышеуказанные методы с такими, как

- метод **Флетчера-Ривса**;
- метод **Дэвидона-Флетчера-Пауэлла**.

## 2. Метод оптимального градиентного поиска (метод Коши)

Этот метод **первого порядка** основан на определении **локального направления** **наискорейшего убывания** целевой функции  $f(x)$  из некоторой произвольной точки  $x^{(k)}$ .

- Что это за **локальное направление наискорейшего убывания** функции  $f(x)$ ?

Определим его аналитически. Для этого разложим целевую функцию в окрестности точки  $x^{(k)}$  в ряд Тейлора до линейного члена включительно, т.е. найдем линейную аппроксимационную функцию:

$$f(x, x^{(k)}) = f(x^{(k)}) + \nabla f(x^{(k)})^T \Delta x + \dots, \quad (3.2)$$

где  $\nabla f(x^{(k)})$  – вектор-градиент в точке разложения;

$\Delta x = (x^{(k)} - x)$  – вектор приращения аргумента.

Из (3.2) видно, что **локальное** уменьшение целевой функции  $f(x, x^{(k)})$  определяется только вторым слагаемым, т.к.  $f(x^{(k)})$  фиксировано.

**Тогда наибольшее локальное** уменьшение  $f(x, x^{(k)})$  связано с выбором такого направления  $\Delta x$ , при котором второе слагаемое, т.е. скалярное произведение в (3.2) будет **максимальным и отрицательным**.

Из свойства скалярного произведения следует, что указанные требования обеспечиваются при условии выбора **антиградиентного** направления, т.е.

$$\Delta x = -\nabla f(x^{(k)}). \quad (3.2a)$$

Подставляя найденное направление  $-\nabla f(x^{(k)})$  в формулу (3.1) получим **формулу градиентного поиска**

$$x^{(k+1)} = x^{(k)} - t_k \nabla f(x^{(k)}), \quad k=0, 1, 2, \dots, \quad (3.3)$$

где  $t_k > 0$  – **скалярная величина**, задающая **длину шага** поиска, и пока неизвестная.

Определим ее. Говорят, что если  $t_k$  является **решением одномерной задачи минимизации**

$$f(x^{(k)} - t_k \nabla f(x^{(k)})) \rightarrow \min_{t_k > 0}, \quad (3.4)$$

то в этом случае формулы (3.3) и (3.4) представляют **оптимальный** градиентный метод, или, что то же – **метод Коши**<sup>1</sup>.

### • Краткое обсуждение работы оптимального градиентного метода

Согласно этому методу, **следующая точка поиска**  $x^{(k+1)}$  вычисляется так, что:

<sup>1</sup> Оптимальный градиентный метод часто называется методом наискорейшего спуска, или методом Коши, который первый использовал аналогичный алгоритм для решения систем линейных уравнений (Коши Огюстен Луи – (1789–1857гг), французский математик)

**во-первых**, она расположена в направлении **антиградиента**  $-\nabla f(x^{(k)})$ ;

**во-вторых**, функция  $f(x^{(k+1)})$  в этой точке **принимает минимальное значение**.

Далее итерация повторяется: вновь определяется антиградиент в точке  $x^{(k+1)}$  и т.д. Одномерная задача (3.4) вычисления  $t_k$  может решаться любым из методов **одномерного поиска** (см. л/р №2).

Важно также отметить, что эпитет **«оптимальный»** в названии метода указывает просто на тот факт, что в качестве следующей точки выбирается точка, лежащая на прямой антиградиента  $(x^{(k)} - \nabla f(x^{(k)}))$  и являющаяся на этой **прямой точкой минимума («оптимума»)** функции  $f(x)$ . Значит термин «оптимальный» не говорит о том, что метод Коши обладает какими-либо **иными** оптимальными свойствами, например, способностью осуществлять поиск минимальной точки за минимальное число шагов.

Иногда параметр шага не вычисляется, а просто задается. Градиентный метод, в котором параметр шага  $t_k$  берется относительно малой величиной для всех шагов, называют **градиентным методом с малым шагом**. В **градиентных методах с большим шагом** параметр шага  $t_k$  назначается больше оптимального значения.

### • Пример 3.1. Оптимальный градиентный метод (метод Коши)

Рассмотрим квадратичную функцию  $f(x) = 8x_1^2 + 4x_1x_2 + 5x_2^2$  и используем метод Коши для ее минимизации.

**Решение.** Компоненты вектор-градиента  $\Delta f(x)$  равны

$$\partial f / \partial x_1 = \nabla f_1 = 16x_1 + 4x_2,$$

$$\partial f / \partial x_2 = \nabla f_2 = 10x_2 + 4x_1,$$

$$\text{т.е. } \Delta f(x) = (16x_1 + 4x_2, 10x_2 + 4x_1)^T.$$

Зададим начальное приближение, например  $x^0 = (10, 10)^T$  и с помощью формулы (3.3) построим новое приближение:

$$x^{(1)} = x^{(0)} - t_0 \nabla f(x^{(0)}),$$

решая задачу одномерной минимизации (3.4) относительно скалярного параметра  $t_0$ :

$$8(x_1^{(0)} - t_0 \nabla f_1)^2 + 4(x_1^{(0)} - t_0 \nabla f_1)(x_2^{(0)} - t_0 \nabla f_2) + 5(x_2^{(0)} - t_0 \nabla f_2)^2 \rightarrow \min$$

найдем, что  $t_0 = 0.056$ .

Следовательно, из начальной точки  $x^{(0)}$  мы переходим в следующую точку поиска:


$$x^{(1)} = (-1.20, 2.16)^T.$$

Далее, повторяя итерации, получим данные, которые сведены в табл.3.1.

**Таблица 3.1.** Результаты минимизации методом Коши

Номер итерации (k)	Составляющая $x_1^{(k)}$	Составляющая $x_2^{(k)}$	Значение функции $f(x^{(k)})$
0	10.0000	10.0000	1700.0000
1	- 1.2403	2.1181	24.2300
2	0.1441	0.1447	0.3540
3	- 0.0181	0.0309	0.0052
4	0.0021	0.0021	0.0000

По данным табл. 3.1 построим на фоне линий равного уровня целевой функции  $f(x)$  **три начальных шага траектории Коши** (рис.3.1) :



**Рис. 3.1.** Три начальные итерации (шага) метода Коши поиска минимума из начальной точки  $x^0$

Как видно из рис. 3.1, траектория Коши носит зигзагообразный характер, причем, можно доказать, что шаги траектории **взаимно ортогональны**.

Анализ данных табл. 3.1 показывает, что метод Коши позволяет существенно уменьшить значение целевой функции при движении из точек, расположенных на значительных расстояниях от точки минимума, и поэтому могут использоваться при реализации градиентных методов в качестве начальной процедуры.

#### • Представим основные операции алгоритма Коши

1. Задать  $M, x^{(0)}, \varepsilon_1, \varepsilon_2$ .
2. Положить  $k=0$ .
3. Вычислить градиент  $\nabla f(x^{(k)})$ .
4. Если  $\|\nabla f(x^{(0)})\| \leq \varepsilon_1$ , то перейти к 10.

5. Если  $M \leq k$ , то перейти к 10.
6. Вычислить  $t_k$  любым одномерным методом с точностью  $\varepsilon_2$ .
7. Положить  $x^{(k+1)} = x^{(k)} - t_k \nabla f(x^{(k)})$ .
8. Если  $\|x^{(k+1)} - x^{(k)}\| / \|x^{(k)}\| \leq \varepsilon_1$ , то перейти к 10.
9. Положить  $k=k+1$ ; перейти к 3.
10. Печать результатов; стоп.

### 3. Метод Ньютона

Метод основывается на **квадратичной аппроксимации** рядом Тейлора функции  $f(x)$  в окрестности точки  $x^{(k)}$ . Это значит, что в методе Ньютона используется информация о **вторых производных**  $f(x)$ , т.е. о матрице Гессе. Поэтому он относится к методам **второго порядка**.

Для вывода **итерационной формулы** метода Ньютона разложим  $f(x)$  в ряд Тейлора до второго члена включительно. Получим **аппроксимирующую функцию** в окрестности точки  $x^{(k)}$ :

$$f(x; x^{(k)}) = f(x^{(k)}) + \nabla f(x^{(k)})^T \Delta x + \frac{1}{2} \Delta x^T \nabla^2 f(x^{(k)}) \Delta x, \quad (3.5)$$

где  $\nabla^2 f(x^{(k)}) = H(x^{(k)})$  – симметрическая квадратная матрица **вторых частных производных** функции  $f(x)$ , или **матрица Гессе**.

Запомните основную идею, на которой базируется итерационная формула Ньютона:

нужно вычислять последовательность итераций таким образом, **чтобы во вновь получаемой точке  $x^{(k+1)}$  градиент аппроксимирующей функции (3.5) обращался в нуль.**

Тогда формально можно записать:

$$\nabla f(x; x^{(k)}) = \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) \Delta x = 0,$$

откуда искомое направление поиска в методе Ньютона равно

$$\Delta x = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}) = -H^{-1}(x^{(k)}) \nabla f(x^{(k)}). \quad (3.5a)$$

Обратите внимание, что в формуле **направление Ньютона** равно антиградиентному направлению, умноженному на обратную матрицу Гессе. Полезно сравнить направление Коши (3.2a) с направлением Ньютона (3.5a).

Последовательное применение на каждой итерации указанной схемы квадратичной аппроксимации, составляет существо метода Ньютона, т.е. итерации производятся по формуле

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}), \quad (3.6)$$

или, введя другое обозначение матрицы Гессе, окончательно получим:

$$x^{(k+1)} = x^{(k)} - H^{-1}(x^{(k)}) \nabla f(x^{(k)}). \quad (3.7)$$

Это последняя формула и определяет **метод Ньютона**.

### • Пример 3.2. Минимизация методом Ньютона

Рассмотрим вновь функцию из предыдущего примера  $f(x) = 8x_1^2 + 4x_1x_2 + 5x_2^2$  и минимизируем ее методом Ньютона.

Градиент целевой функции  $\nabla f(x)$  равен:

$$\nabla f(x) = (16x_1 + 4x_2, 4x_1 + 10x_2)^T,$$

а матрица Гессе  $\nabla^2 f(x) = H(x)$  такая:

$$\nabla^2 f(x) = H(x) = \begin{bmatrix} 16 & 4 \\ 4 & 10 \end{bmatrix}.$$

Зададим ту же начальную точку  $x^0 = (10, 10)^T$ .

Тогда по формуле (3.5) или (3.6) получим следующую точку поиска:

$$x^{(1)} = (10, 10)^T - (1/144) \begin{bmatrix} 10 & -4 \\ -4 & 16 \end{bmatrix} (200, 140)^T,$$

т.е.:

$$x^{(1)} = (10, 10)^T - (1/144) (1440, 1440)^T = (0, 0)^T,$$

что соответствует **точному решению этой задачи**.

Таким образом, метод Ньютона для квадратичной целевой функции за один шаг достигает точки минимума.

Это означает, что данный метод вырабатывает из любой начальной точки **глобальное направление поиска** – но только для квадратичных форм.

## 4. Модифицированный метод Ньютона

Заметим, что предыдущий метод Ньютона **не регулирует длину шага**. Хорошо это или плохо? Как показывает практика применения метода для не квадратичных функций, **сходимость** метода к минимуму сильно зависит от выбора начальной точки поиска (вспомните свойства сходимости метода Ньютона для одномерного поиска – см. лабораторную работу №1)

Поэтому сейчас полезно проанализировать **условия сходимости метода**.

По определению известно, что направление поиска  $s(x)$  является направлением уменьшения функции (направлением спуска), если **имеет место неравенство**  $\nabla f(x)^T s(x) < 0$ . Тогда из формулы метода Ньютона (3.6) следует, что должно выполняться неравенство

$$-\nabla f(x)^T \nabla^2 f(x)^{-1} \nabla f(x) < 0.$$

Нетрудно видеть, что в случае, когда матрица Гессе  $\nabla^2 f(x)$  **положительно знакоопределена**, это условие выполняется, т.е. направление поиска по методу Ньютона оказывается **направлением спуска**.

Однако, если в некоторой точке траектории поиска матрица  $\nabla^2 f(x)$  становится **отрицательно знакоопределена**, то указанное направление является **направлением подъема**, а в случае **неопределенности** матрицы Гессе однозначный вывод о сходимости метода сделать нельзя и требуются дополнительные исследования.

- Как уже было отмечено, опыт практической оптимизации показывает, что при минимизации **не квадратичных функций**, метод Ньютона не отличается высокой надежностью.

Это происходит из-за того, что если начальная точка поиска находится достаточно далеко от минимума, то **шаг Ньютона** часто оказывается **чрезмерно большим**. Это может привести к расходящемуся итерационному процессу минимизации.

В **таких ситуациях**<sup>1</sup> нужно применять **модифицированный метод Ньютона**, в котором итерации вычисляются по формуле

$$x^{(k+1)} = x^{(k)} - t_k H^{-1}(x^{(k)}) \nabla f(x^{(k)}), \quad (3.8)$$

где  $t_k$  – **параметр шага**, аналогичный используемому в методе Коши.

Модифицированный метод Ньютона отличается высокой скоростью сходимости, но на каждой итерации требует вычислений элементов обратной матрицы Гессе.

## 5. Метод Марквардта: комбинация методов Коши и Ньютона

- Желание использовать методы Коши и Ньютона так, чтобы вдали от точки минимума поиск проводился в антиградиентном направлении, а по мере приближения к минимуму, использовались итерации по ньютоновскому направлению, привело исследователей к созданию **метода Марквардта**, суть которого заключается в следующем.

Если направление поиска  $s(x^{(k)})$  в точке  $x^{(k)}$  вычислять по формуле

$$s(x^{(k)}) = -(H^{(k)} + \lambda_k \mathbf{I})^{-1} \nabla f(x^{(k)}), \quad (3.9)$$

где  $H^{(k)}$  – матрица Гессе точке  $x^{(k)}$ ;

$\lambda_k$  – некоторая скалярная величина;

$\mathbf{I}$  – единичная матрица  $N \times N$ ,

то в зависимости от выбора величины  $\lambda_k$  направление  $s(x^{(k)})$  может меняться от антиградиентного до ньютоновского.

Действительно, задав на начальной стадии поиска большое значение параметра  $\lambda_0 = (10^4 \div 10^6)$ , имеем

$$(H^{(0)} + \lambda_0 \mathbf{I})^{-1} = (\lambda_0 \mathbf{I})^{-1} = (1/\lambda_0) \mathbf{I}.$$

Т.е. большим значениям  $\lambda_k$  в (3.9) соответствует антиградиентное направление или близкое к нему.

С другой стороны, можно показать, что при малых значениях  $\lambda_k$  формула (3.9) будет «вырабатывать» направление Ньютона.

<sup>1</sup> Каким образом графически характеризуется термин «такая ситуация»?

- При программной реализации метода Марквардта управлять выбором значений  $\lambda_k$  рекомендуется путем сравнения значений функции на каждой итерации:

- если целевая функция на текущей итерации уменьшилась, то следует уменьшить величину  $\lambda_k$  и реализовать очередной шаг;

- в противном случае следует положить  $\lambda_{k+1} = \beta \lambda_k$ , где  $\beta > 0$ , и вновь повторить шаг поиска.

Метод Марквардта характеризуется относительной простотой, свойством убывания целевой функции при переходе от итерации к итерации, высокой скоростью сходимости в окрестности точки минимума, а также отсутствием процедуры одномерной минимизации.

**Следующий раздел – только по специальному указанию преподавателя.**

## 6. Методы сопряженных градиентов- наиболее эффективная группа методов

Вкратце рассмотрим методы **флетчера-Ривса** и **Дэвидона-флетчера-Пауэлла**, которые составляют группу методов **сопряженных градиентов**.

В работе 2 данного курса был рассмотрен метод сопряженных направлений Пауэлла, с помощью которого можно находить сопряженные направления только для квадратичных функций, причем для этого использовалась информация о значениях целевой функции.

Теперь же мы попытаемся минимизировать функцию общего вида, используя значения *квадратичной аппроксимации* исходной функции и значения *компонент градиента*. Кроме того, мы потребуем, чтобы на каждой итерации обеспечивалось уменьшение целевой функции.

Теория методов сопряженных градиентов базируется на следующем свойстве квадратичных форм.

Пусть в пространстве переменных заданы две произвольные несовпадающие точки  $x^{(0)}$  и  $x^{(1)}$ . Как известно, градиент квадратичной функции  $q(x) = \frac{1}{2} x^T Q x + b^T x + a$  равен

$$\nabla f(x) = \nabla q(x) = Qx + b = g(x).$$

Обозначение  $g(x)$  введено для удобства записи дальнейших выкладок.

Таким образом,

$$g(x^{(0)}) = Qx^{(0)} + b,$$

$$g(x^{(1)}) = Qx^{(1)} + b.$$

Запишем **изменение градиента при переходе от точки  $x^{(0)}$  к точке  $x^{(1)}$** :

$$\Delta g(x) = g(x^{(1)}) - g(x^{(0)}) = Q(x^{(1)} - x^{(0)}),$$

$$\Delta g(x) = Q\Delta x. \quad (3.10)$$

Это последнее равенство (3.10) и выражает очередное свойство квадратичных функций, которое будет использовано дальше.



Эстенс и Штифель (1952г) предложили эффективный итерационный алгоритм для решения систем линейных уравнений, который по существу представлял собой метод сопряженных градиентов. Они рассматривали левые части линейных уравнений как компоненты градиента квадратичной функции и решали задачу минимизации этой функции.

Напомним, что решение системы  $N$  линейных уравнений  $\mathbf{Ax}=\mathbf{b}$ , эквивалентно минимизации квадратичной функции

$$q(x) = (\mathbf{Ax}-\mathbf{b})^T (\mathbf{Ax}-\mathbf{b}) .$$

Позже Флетчер и Ривс обосновали квадратичную сходимость метода и обобщили его для случая не квадратичных функций.

Вывод итерационной формулы метода Флетчера-Ривса проведем в предположении, что целевая функция является квадратичной  $q(x) = \frac{1}{2} x^T \mathbf{Q} x + b^T x + a$ , а итерации проводятся по основной формуле  $x^{(k+1)} = x^{(k)} + t_k s(x^{(k)})$ . Это не сужает общности рассуждений, поскольку в случае не квадратичной целевой функции матрицу квадратичной функции  $\mathbf{Q}$  необходимо заменить матрицей Гессе  $\mathbf{H}$  исходной функции. Направление поиска на каждой итерации определяются с помощью следующих формул:

$$s^{(k)} = -g^{(k)} + \sum_{i=0}^{k-1} \gamma^{(i)} s^{(i)} ,$$

$$s^{(0)} = -g^{(0)} ,$$

где  $g^{(0)} = \nabla f(x^{(k)})$ .

Так как после определения системы направлений проводится последовательный поиск вдоль каждого из направлений, полезно напомнить, что в качестве критерия окончания одномерного поиска обычно используется условие

$$\nabla f(x^{(k+1)})^T s^{(k)} = 0 . \quad (3.11)$$

Значения  $\gamma^{(i)}$ ,  $i=1,2,3, \dots, k-1$ , выбираются таким образом, чтобы направление  $s^{(k)}$  было  $\mathbf{Q}$ -сопряжено со всеми построенными ранее направлениями поиска.

Рассмотрим первое направление

$$s^{(1)} = -g^{(1)} + \gamma^{(0)} s^{(0)} = -g^{(1)} - \gamma^{(0)} g^{(0)}$$

и наложим на него условие сопряженности с  $s^{(0)}$

$$s^{(1)T} \mathbf{Q} s^{(0)} = 0 ,$$

откуда следует, что

$$[g^{(1)} + \gamma^{(0)} g^{(0)}]^T \mathbf{Q} s^{(0)} = 0 .$$

На начальной итерации

$$s^{(0)} = \Delta x / t^{(0)} ;$$

следовательно,

$$[g^{(1)} + \gamma^{(0)} g^{(0)}]^T \mathbf{Q} [\Delta x / t^{(0)}] = 0 .$$

Используя выведенное выше свойство (3.10) квадратичных функций, получаем

$$[g^{(1)} + \gamma^{(0)} g^{(0)}]^T \Delta g = 0, \quad (3.12)$$

откуда

$$\gamma^{(0)} = -(\Delta g^T g^{(1)}) / (\Delta g^T g^{(0)}).$$

Из уравнения (3.12) следует, что

$$g^{(1)T} g^{(1)} + \gamma^{(0)} g^{(0)T} g^{(1)} - g^{(1)T} g^{(0)} - \gamma^{(0)} g^{(0)T} g^{(0)} = 0.$$

При соответствующем выборе параметра одномерного поиска  $t^{(0)}$  и с учетом формулы (3.11) имеем

$$g^{(1)T} g^{(0)} = 0.$$

Таким образом,

$$\gamma^{(0)} = \|g^{(1)}\|^2 / \|g^{(0)}\|^2.$$

Далее определим следующее направление поиска

$$s^{(2)} = -g^{(2)} + \gamma^{(0)} s^{(0)} + \gamma^{(1)} s^{(1)}$$

и выберем  $\gamma^{(0)}$  и  $\gamma^{(1)}$  таким образом, чтобы выполнялись условия

$$s^{(2)T} Q s^{(0)} = 0 \text{ и } s^{(2)T} Q s^{(1)} = 0,$$

т.е. условия  $Q$ -сопряженности направления  $s^{(2)}$  с направлениями  $s^{(0)}$  и  $s^{(1)}$ .

С помощью формул (3.10) и (3.11) можно показать, что здесь  $\gamma^{(0)} = 0$ , а в общем случае  $\gamma^{(i)} = 0$ ,  $i = 0, 1, 2, \dots, k-2$ , при любом значении  $k$ . Отсюда следует, что общая формула для направлений поиска метода Флетчера-Ривса может быть записана в виде:

$$s^{(k)} = -g^{(k)} + [\|g^{(k)}\|^2 / \|g^{(k-1)}\|^2] s^{(k-1)}.$$

Если целевая  $N$ -мерная функция квадратичная, то для минимизации потребуется определить ровно  $N-1$  таких направлений и провести ровно  $N$  одномерных поисков вдоль этих направлений.

Если же функция общего вида, то количество направлений и одномерных поисков возрастает.

Метод **Дэвидона-Флетчера-Пауэлла** (метод **ДФП**) подобен предыдущему методу, поскольку также основан на свойствах квадратичных функций. Однако метод ДФП вырабатывает ньютоновское направление поиска, причем используя при этом информацию только о первых производных целевой функции. Методы подобного рода достаточно эффективны и составляют целый класс методов, называемых методами *переменной метрики* или *квазиньютоновскими* методами.

В этих методах итерации производятся также по общей формуле (3.1), а направление  $s(x^{(k)})$  вычисляется так:

$$s(x^{(k)}) = -A^{(k)} \nabla f(x^{(k)}),$$

где  $A^{(k)}$  – матрица порядка  $N \times N$ , которая носит название *метрики*<sup>2</sup>.

<sup>2</sup> Метрика (от греч. – мера, размер) – расстояние между двумя точками (элементами)  $a, b$  множества  $A$ , т.е. действительная числовая функция, удовлетворяющая трем свойствам расстояния. Например, метрика может быть обычным евклидовым расстоянием. Метрики обычно задаются соответствующей нормой.

Согласно принятой классификации метод является квазиньютоновским, если в соответствии с ним перемещение пробной точки удовлетворяет следующему условию:

$$\Delta x = \mathbf{H}^{-1} \Delta g, \quad (3.13)$$

где  $\mathbf{H}^{-1}$  – обратная матрица в  $k$ -й точке.

В квазиньютоновских методах на каждой итерации обратная матрица Гессе целевой функции аппроксимируется с помощью вычисления составляющих вектора-градиента. Обоснование возможности такой аппроксимации заключается в следующем. Запишем для некоторой симметрической матрицы  $\mathbf{A}$  следующее рекуррентное соотношение:

$$\mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} + \mathbf{A}_c^{(k)}, \quad (3.14)$$

где  $\mathbf{A}_c^{(k)}$  – корректирующая матрица.

Задача заключается в том, чтобы построить матрицу  $\mathbf{A}^{(k)}$  таким образом, чтобы последовательность матриц  $\mathbf{A}^{(0)}, \mathbf{A}^{(1)}, \mathbf{A}^{(2)}, \dots, \mathbf{A}^{(k+1)}$  давала приближение к обратной матрице Гессе целевой функции  $\mathbf{H}^{-1} = \nabla^2 f(x^*)^{-1}$  в точке минимума; при этом для получения решения  $x^*$  требуется один дополнительный поиск вдоль прямой, если целевая функция – квадратичная.

Как неоднократно подчеркивается в литературе по теории оптимизации, имеются определенные основания полагать, что метод, обеспечивающий нахождение оптимумов квадратичных функций, может привести к успеху при решении задач с нелинейными целевыми функциями общего вида.

Вернемся к важному свойству (3.10) квадратичных форм, которое переписано в виде (3.13), и предположим, что матрица  $\mathbf{H}^{-1}$  аппроксимируется по формуле

$$\mathbf{H}^{-1} = \beta \mathbf{A}^{(k)}, \quad (3.15)$$

где  $\beta$  – скалярная величина.

Наиболее предпочтительным является приближение, удовлетворяющее (3.13), т.е.

$$\Delta x^{(k)} = \mathbf{A}^{(k)} \Delta g^{(k)},$$

где  $\Delta x^{(k)} = x^{(k+1)} - x^{(k)}$ ,  $\Delta g^{(k)} = g(x^{(k+1)}) - g(x^{(k)})$ ; (здесь уместно напомнить, что выше мы приняли обозначение  $\nabla f(x) = g(x)$ ).

Однако ясно, что такую аппроксимацию построить невозможно, поскольку для того, чтобы найти  $\Delta g^{(k)}$ , необходимо знать матрицу  $\mathbf{A}^{(k)}$ .

С другой стороны, можно потребовать, чтобы новое приближение удовлетворяло формуле (3.13):

$$\Delta x^{(k)} = \beta \mathbf{A}^{(k+1)} \Delta g^{(k)}. \quad (3.16)$$

Подставляя (3.14) в (3.16) получаем уравнение

$$\mathbf{A}_c^{(k)} \Delta g^{(k)} = \frac{1}{\beta} \Delta x^{(k)} - \mathbf{A}^{(k)} \Delta g^{(k)},$$

решением которого является следующая матрица

$$\mathbf{A}_c^{(k)} = \frac{1}{\beta} \left( \frac{\Delta \mathbf{x}^{(k)} \mathbf{y}^T}{\mathbf{y}^T \Delta \mathbf{g}^{(k)}} \right) - \frac{\mathbf{A}^{(k)} \Delta \mathbf{g}^{(k)} \mathbf{z}^T}{\mathbf{z}^T \Delta \mathbf{g}^{(k)}}, \quad (3.17)$$

в чем можно убедиться путем непосредственной подстановки.

Здесь  $\mathbf{y}$  и  $\mathbf{z}$  – некоторые произвольные векторы, т.е. формула (3.17) определяет некоторое семейство решений.

Если положить  $\mathbf{y} = \Delta \mathbf{x}^{(k)}$  и  $\mathbf{z} = \mathbf{A}^{(k)} \Delta \mathbf{g}^{(k)}$ ,

то получим формулу искомую, реализующую известный и широко применяемый метод Дэвидона–Флетчера–Пауэлла:

$$\mathbf{A}^{(k)} = \mathbf{A}^{(k-1)} + \frac{\Delta \mathbf{x}^{(k-1)} \Delta \mathbf{x}^{(k-1)T}}{\Delta \mathbf{x}^{(k-1)T} \Delta \mathbf{g}^{(k-1)}} - \frac{\mathbf{A}^{(k-1)} \Delta \mathbf{g}^{(k-1)} \Delta \mathbf{g}^{(k-1)T} \mathbf{A}^{(k-1)}}{\Delta \mathbf{g}^{(k-1)T} \mathbf{A}^{(k-1)} \Delta \mathbf{g}^{(k-1)}}. \quad (3.18)$$

В теории оптимизации доказывается, что эта рекуррентная формула сохраняет свойства симметрии и положительной определенности матриц. Поэтому, если  $\mathbf{A}^{(0)}$  – положительно определенная матрица, то матрицы  $\mathbf{A}^{(1)}$ ,  $\mathbf{A}^{(2)}$ , ... также оказываются симметрическими и положительно определенными при отсутствии ошибок округления; обычно удобно выбирать  $\mathbf{A}^{(0)} = \mathbf{I}$ . Также можно доказать, что данный метод обеспечивает уменьшение функции на каждой итерации. Метод ДФП в течение ряда лет продолжает оставаться наиболее широко используемым методом оптимизации. Он отличается устойчивостью и успешно применяется при решении самых различных задач, возникающих на практике.

Недостатком методов такого типа является необходимость хранить в памяти компьютера матрицу  $\mathbf{A}$  порядка  $N \times N$ . Однако более существенным недостатком является то, что в связи с неточностью вычислительных процедур накапливаемая ошибка может привести к тому, что на определенной итерации матрица  $\mathbf{A}$  может оказаться плохо обусловленной и поэтому возникает необходимость возврата к некоторой предыдущей итерации с пересмотренной метрикой. В принципе, при написании надежных программ минимизации данным методом рекомендуется на каждом шаге проверять обусловленность матрицы  $\mathbf{A}$ , хотя такая дополнительная процедура увеличивает трудоемкость вычислений.

**На этом заканчивается описание теоретической части работы №3.**

## 7. Практическая часть

### Общие замечания

■ **Напомним**, что основной целью работы является **изучение** практических аспектов градиентных методов минимизации **и их сравнение**.

Также важно провести **сравнение** этих методов с методами **прямого поиска** из предыдущей работы №2 «Алгоритмы прямого поиска в многомерной минимизации».

• Чтобы **корректно сравнивать** методы, в этой работе нужно минимизировать те же три двумерные функции  $f_1(x)$ ,  $f_2(x)$  и  $f_3(x)$ , которые использовались в работе №2:

$$\begin{aligned}f_1(\mathbf{x}) &= 12x_1^2 + 6x_1 x_2 + 2x_2^2 - 2x_1 - x_2 ; \\f_2(\mathbf{x}) &= 0.5 (x_2 - x_1^2)^2 + (1 - x_1)^2 ; \\f_3(\mathbf{x}) &= 100 (x_2 - x_1^2)^2 + (1 - x_1)^2 .\end{aligned}$$

Естественно, что для изучения методов нам понадобятся соответствующие **программы**, реализующие поиск минимума соответствующим методом.

Ряд программ **прилагаются** к данной работе как **готовые exe-файлы**, а некоторые – нужно **разработать самостоятельно**.

**Самостоятельно** нужно запрограммировать 3 следующих метода:

1. градиентный метод с **аналитическим вычислением градиента  $\nabla f$**  и ручным **заданием параметра длины шага  $t_k$** ;
2. метод Коши с **аналитическим градиентом  $\nabla f$**  и **аналитическим вычислением** параметра длины шага  $t_k$ ;
3. метод Коши с **аналитическим градиентом  $\nabla f$**  и с каким-либо **интервальным методом** вычисления параметра шага  $t_k$ .

Для изучения методов **Ньютона, Флетчера-Ривса и Дэвидона-Флетчера-Пауэлла** нужно<sup>3</sup> использовать прилагаемые к работе готовые учебные программы:

4. **nt\_r**, – метод Ньютона для минимизации функции Розенброка;
5. **nmod\_r** – модифицированный метод Ньютона;
6. **fr\_r** – метод Флетчера-Ривса;
7. **dfp\_r** – метод Дэвидона-Флетчера-Пауэлла.

После выполнения Практической части 7, можно приступить к ответам на контрольные вопросы (часть 8). Обычно, в других лабораторных работах, ответы на контрольные вопросы предшествуют практической части. Мы считаем, что в этой работе контрольные вопросы таковы, что квалифицированные ответы на них проще дать после выполнения части 7.

Теперь переходите к выполнению конкретных пунктов Практической части 7 данной лабораторной работы.

## ИЗУЧЕНИЕ МЕТОДА КОШИ

**7/1/9. Вначале** запрограммируйте **градиентный метод** для минимизации функции  $f_1(\mathbf{x})$  с **аналитическим** вычислением градиента  $\nabla f$  и **ручным** вводом параметра длины шага  $t_k = \text{const}$ , который остается постоянным для всех итераций данного конкретного поиска. Значения  $t$  даны ниже.

Это нестандартная программа, носящая учебно-иллюстративный характер. По существу, она должна отвечать на вопрос:

---

<sup>3</sup> Не исключается, что обучающийся может разработать свои собственные программы, что априори значительно повышает его рейтинг при сдаче работы преподавателю.

«каковы будут **начальные** шаги траектории (**не менее 5**) минимизации градиентным методом, если параметр длины шага  $t_k = \text{const}$  **задается не оптимальным**: либо **большим**, либо **малым**, либо остается постоянным на каждом шаге траектории?»

Несмотря на свою «нестандартность», эта программа должна содержать все необходимые процедуры интерактивных программ градиентных методов:

- 1) реквизиты программы и меню ввода исходных данных,
- 2) процедуру вычисления направления в виде градиента  $\nabla f$ ,
- 3) процедуру проверки правила останова по норме  $\nabla f$ ,
- 4) процедуру оценки параметра шага  $t_k$ , (в первой программе эта процедура отсутствует, т.к.  $t$  нужно задавать),
- 5) процедуру вычисления следующей точки поиска,
- 6) процедура вывода данных поиска минимума.

Теперь становится ясным, что данная программа должна стать основой для самостоятельной разработки следующих программ. Действительно, достаточно ввести соответствующим образом процедуру 4) оценки параметра шага  $t$ , можно получить другие требуемые в работе программы. Поэтому обратите **особое внимание** на обсуждаемую программу.

Чтобы построить по 5 шагов требуемых в данном пункте траекторий, полезно выводить данные, которые перечислены в табл. 3.2. (Не надо заносить координаты траектории в таблицу, а сразу переносите их с экрана на график).

Итак, сделав программу градиентного поиска, постройте с ее помощью **по 5 начальных шагов траекторий** минимизации функции  $f_1$  с такими начальными данными:

- из точки  $(2, 2)^T$  с постоянным параметром шага на каждой итерации: вначале при  $t=0.02$ , а затем с  $t=0.005$ ;
- из точки  $(2.1, -1.5)^T$  с постоянным параметром  $t=0.07$  на каждой итерации, а затем с  $t=0.005$ ;
- на фоне линий уровня  $f_1$  нарисуйте **все 4 траектории** поиска;
- поясните эти траекторий минимизации.

**7/2/9. Запрограммируйте метод Коши с аналитическим градиентом и аналитическим параметром шага  $t_k$  для минимизации только функции  $f_1$ .**

- После отладки этой программы метода, минимизируйте функцию  $f_1$  из начальной точки  $(2, 2)^T$  с **точностью  $\varepsilon=1e-6$** . Результаты работы программы минимизации  $f_1$  сведите в **табл. 3.2**. Чтобы таблица была

обозримой, запишите данные **только 4-х** начальных шагов и **конечный результат**.

**Таблица 3.2. Результаты минимизации  $f_1(x)$**

Итерация k	$x_1$	$x_2$	$f_1(x)$	$t_k$	$\ \nabla f_1(x)\ $
0					
1					
2					
3					
4					
...					
$K_{\text{кон}}$					

■ По данным табл. 3.2 на фоне линий равного уровня функции  $f_1$  постройте **4 начальных** шага минимизации и конечную точку траектории. (Рисунок сделайте как минимум на половине листа формата A4).

Сравните эту траекторию с траекториями предыдущего пункта.

■ На рисунке предыдущего пункта постройте (примерно) траекторию минимизации **релаксационным** методом. (Используйте ту же начальную точку, что и в табл. 3.2. Поясните различия в траекториях, если таковые имеются.)

■ Возьмите какую-либо пару последовательных шагов траектории и **аналитически** проверьте их ортогональность.

### 7/3/9. Запрограммируйте метод Коши для минимизации функций $f_1, f_2, f_3$ .

■ В программах для всех функций используйте **аналитическое вычисление градиента** и любой известный вам **численный метод одномерного поиска** для вычисления параметра шага  $t_k$ .

**Указание.** Перед разработкой программы, изучите блок-схему алгоритма, обратив особое внимание на то, как вычисляется оптимальный параметр шага, т.е. на процедуру **одномерного поиска** в двумерной минимизации. Для этого полезно использовать опыт программирования метода Пауэлла в части организации одномерного поиска (лабораторная работа №2).

### 7/4/9. Сравнение методов Коши, Ньютона и Флетчера-Ривса

Для выполнения данного пункта работы используйте вашу программу метода Коши предыдущего п.7/3/9 и программы, **прилагаемые** к данной работе:

**nt\_q** – метод Ньютона для квадратичной функции  $f_1$ ;

**nt\_r** – метод Ньютона для функции Розенброка  $f_2, f_3$ ;

**fr\_q, fr\_r** – метод Флетчера-Ривса для тех же функций  $f_1 \div f_3$ .

Задаваемые исходные данные вычислительного эксперимента:

- **точность поиска  $\varepsilon=10^{-6}$  и одинакова для всех задач;**
- **только для функции  $f_1(x)$**  координаты пары начальных точек поиска нужно выбрать из списка и согласовать с преподавателем:

вариант 1:  $x^{01}=(2, 2)^T$ ,  $x^{02}=(1.4, -2.5)^T$

вариант 2:  $x^{01}=(0.5, -2.8)^T$ ,  $x^{02}=(-2.7, 0.5)^T$

вариант 3:  $x^{01}=(-2.5, -1)^T$ ,  $x^{02}=(2.7, 0)^T$

вариант 4:  $x^{01}=(-2, 2)^T$ ,  $x^{02}=(0.5, -2.8)^T$

вариант 5:  $x^{01}=(-1, 2.75)^T$ ,  $x^{02}=(2, 2)^T$

вариант 7:  $x^{01}=(2.7, 0)^T$ ,  $x^{02}=(-1, 2.75)^T$

(Начальные точки заданы так, что они располагаются приблизительно на одинаковом расстоянии до искомой точки минимума).

**для функций Розенброка  $f_2(x)$  и  $f_3(x)$**  начальные точки заданы в табл. 3.3;

Данные вычислений для удобства сравнения методов необходимо свести в **табл. 3.3**:

**Таблица 3.3. Результаты сравнения методов минимизации**

Метод минимизации Целевая функция	Метод Коши	Метод Ньютона	Метод Флетчера-Ривса
<b>Квадратичная форма</b> $f_1(x) = 12x_1^2 + 6x_1x_2 + 2x_2^2 - 2x_1 - x_2$ <b>Точный минимум</b> $x^* =$ <b>Значение в минимуме</b> $f_1(x^*) =$	1) Нач. точка $x^{01}$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$ 2) Нач. точка $x^{02}$ ...	1) Нач. точка $x^{01}$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$ 2) Нач. точка $x^{02}$ ...	1) Нач. точка $x^{01}$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$ 2) Нач. точка $x^{02}$ ...
<b>Функция Розенброка</b> $f_2(x) = 0.5(x_2 - x_1^2)^2 + (1 - x_1)^2$ ; <b>Точный минимум</b> $x^* =$ <b>Значение в минимуме</b> $f_2(x^*) =$	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ ...	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ ...	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ ...
<b>Функция Розенброка</b> $f_3(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ ; <b>Точный минимум</b> $x^* =$ <b>Значение в минимуме</b>	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$	1) Нач. точка $x^0=(-1.2, 1)^T$ ... 2) Нач. точка $x^0=(-0.6, -0.6)^T$ $x^{**} =$ $f(x^{**}) =$ $N_{тр} =$



$f_3(x^*) =$			
--------------	--	--	--

**Примечание.** В табл. 3.3. используются уже известные по работе №2 обозначения, а также и новое:  
 $N_{тр}$  - количество шагов траектории минимизации.

### 7/5/9. Модифицированный метод Ньютона

▪ **Модифицированным методом Ньютона** только для функций Розенброка  $f_2(x)$  и  $f_3(x)$  из точки  $x^0 = (-1.4, 1.4)^T$  с точностью  $\varepsilon = 1e-6$  найдите точку минимума и постройте траектории поиска.

▪ Что дает **модификация** метода Ньютона?

Для выполнения данного пункта можно использовать прилагаемую к данной работе программу **NMOD\_R**.

## ЗАКЛЮЧИТЕЛЬНЫЙ РАЗДЕЛ ПРАКТИЧЕСКОЙ ЧАСТИ

Данный раздел работы является заключительным по изучению и закреплению теории основных методов **безусловной минимизации**.

Поэтому, здесь предлагается решить ряд задач минимизации любым из известных вам методов минимизации.

Точность оценки минимума принять равную  $\varepsilon = 10^{-6}$ .

Для каждой задачи обоснуйте выбранный метод и докажете справедливость полученного решения.

### 7/6/9. Минимизируйте функцию

$$f_4(x) = [1.5 - x_1 (1 - x_2)]^2 + [2.25 - x_1 (1 - x_2^2)]^2 + [2.625 - x_1 (1 - x_2^3)]^2.$$

### 7/7/9. Найдите минимум функции

$$f_5(x) = (x_1 - 2)^2 + (x_2 - 1)^2 + \frac{0.04}{-(x_1^2/4) - x_2^2 + 1} + \frac{1}{0.2}(x_1 - 2x_2 + 1)^2.$$

### 7/8/9. Найдите минимум функции

$$f_6(x) = (x_1^2 + x_2 - 11)^2 + (x_1 + x_2^2 - 7)^2.$$

### 7/9/9. Решите задачу (Д.Химмельблау, «Прикладное нелинейное программирование». Мир, М. 1975, стр. 206)

Стоимость  $C$  очищенной нефти, перевозимой морским путем через Малаккский пролив в Японию (**в долларах на килолитр**), зависит от таких основных определяется параметров:

- 1) стоимости неочищенной нефти;
- 2) затрат на страхование;
- 3) таможенных тарифов;
- 4) затрат на фрахт нефти;
- 5) затрат на погрузку и разгрузку;

- 6) платы за морскую стоянку судна;
- 7) затрат, связанных с подводным перекачиванием и хранением;
- 8) стоимости площади под цистернами;
- 9) стоимости очистки и затрат на перевозку продуктов.

Пусть конкретная функция стоимости  $C$  задана в таком виде:

$$C = c_c + c_i + c_x + \frac{2.09 \cdot 10^4 \cdot t^{-0.3017}}{360} + \frac{1.064 \cdot 10^6 \cdot at^{0.4925}}{52.47q \cdot 360} +$$

$$+ \frac{4.242 \cdot 10^4 at^{0.7952} + 1.813 \cdot ip(n + 1.2q)}{52.47q \cdot 360} + \frac{4.25 \cdot 10^3 a(nt + 1.2q)}{52.47q \cdot 360} +$$

$$+ \frac{5.042 \cdot 10^3 q^{-0.1899}}{360} + \frac{0.1049q^{0.671}}{360},$$

где  $a$  – фиксированные ежегодные расходы в относительных величинах (0.20);

$c_c$  – цена неочищенной нефти, долл/кл (12.50);

$c_i$  – страховка, долл/кл (0.90);

$c_x$  – таможенные тарифы, долл/кл (0.90);

$i$  – норма процента (0.10);

$n$  – число портов (2);

$p$  – цена земли, долл/м<sup>2</sup> (7000);

$q$  – производительность установки для очистки нефти, баррель/день;

$t$  – объем танкера, кл.

Считая значения, указанные в скобках заданными, вычислите любым известным вам методом

- **минимальную стоимость нефти,**
- **оптимальный объем танкера, и**
- **производительность установки** для очистки нефти (заметим, что 1кл=6.29баррель).

-----\*

## 8. Контрольные вопросы

8/1/5. Проанализируйте на экстремум следующие функции:

$$f_1(x, y) = x^2 + y^2; \quad f_2(x, y) = x^2 - y^2;$$

$$f_3(x, y) = x^2 + y^3; \quad f_4(x, y) = x^2 - y^3;$$

$$f_5(x, y) = x^2 + y^4; \quad f_6(x, y) = x^2 - y^4.$$

Для каждой функции постройте несколько линий уровня.

**8/2/5. Рассмотрите функцию**  $f(x) = -1/(x_1^2 + x_2^2 + 1)$  **и по методу Ньютона определите аналитически следующую точку поиска**  $x^{(1)}$ , **для заданных двух вариантов начальных точек**  $x^{(0)}$ :

(а)  $x^{(0)} = (0.05, 0.05)^T$ ,

(б)  $x^{(0)} = (0.0, 5)^T$ .

**8/3/5. Постройте следующие вектора**

**8/4/5. Докажите аналитически**, что любая пара последовательных векторов поиска Коши в табл. 3.1 ортогональна.

----- \*\*\* -----